

PHÁT HIỆN GIAN LẬN GIAO DỊCH TÀI CHÍNH

FRAUD DETECTION

Xây dựng mô hình Machine Learning phát hiện giao dịch gian lận
trong thanh toán thẻ & ví điện tử

THỰC HIỆN BỞI NHÓM 12

Thành viên: Trần Trinh Nhân · Võ Quỳnh Ý · Đặng Đức Duy · Nguyễn Hoàng Minh Nhật · Vương Thành Đạt
Nguyễn Ngọc Như Ý · Nguyễn Hữu Khang

Môn học: Nhập môn Khoa học dữ liệu

Tháng 6, 2026

TỔNG QUAN

Tại sao chọn bài toán này?

BỐI CẢNH & THỰC TRẠNG

- Thiệt hại gian lận thẻ toàn cầu đạt 33,8 tỷ USD (Nilson Report 2023) — hệ thống truyền thống không còn đủ nhanh
- Giao dịch trực tuyến bùng nổ; dữ liệu gian lận mất cân bằng nghiêm trọng (dưới 1% là gian lận)
- Hệ thống hiện tại có tỷ lệ cảnh báo sai cao, thiếu khả năng xử lý theo thời gian thực

MỤC TIÊU

- Xây dựng mô hình ML phát hiện gian lận với độ chính xác cao
- Tìm thuật toán tối ưu cho bài toán phân loại mất cân bằng
- Triển khai mô hình dự đoán theo thời gian thực

THIỆT HẠI GIAN LẬN THẺ TOÀN CẦU

33,8

tỷ USD năm 2023, dự kiến vượt 40 tỷ USD vào 2027

Nguồn: Nilson Report, 2023



LOẠI BÀI TOÁN

Phân loại nhị phân

0 = giao dịch hợp lệ

1 = giao dịch gian lận

NGUỒN DỮ LIỆU

Dữ liệu đến từ đâu?

NGUỒN DỮ LIỆU

- Kaggle: Financial Fraud Detection Dataset — 1M Transactions
- Giao dịch thẻ tín dụng & thanh toán số, giai đoạn 2022–2024
- Được xây dựng dựa trên các mẫu hành vi gian lận tài chính thực tế

1,000,000	23	is_fraud
giao dịch	thuộc tính	nhãn mục tiêu


GHI CHÚ DỮ LIỆU

- Không có bản ghi trùng lặp
- Chỉ cột fraud_pattern có giá trị thiếu (98,3%) — do đặc thù chỉ gắn nhãn cho giao dịch gian lận

PHÂN LOẠI THUỘC TÍNH

Định danh	transaction_id, account_id
Thời gian	timestamp, hour_of_day, day_of_week, is_weekend
Giao dịch	amount, merchant_category, merchant_country, mcc_code
Thiết bị & bảo mật	device_type, device_known, ip_risk_score, has_2fa, card_present
Hành vi tài khoản	velocity_1h, amount_vs_avg_ratio, time_since_last_s, account_age_days
Tài chính	credit_limit, is_foreign_txn
Target	is_fraud, fraud_pattern

QUY TRÌNH THỰC HIỆN



KHÁM PHÁ DỮ LIỆU


Chất lượng dữ liệu & mất cân bằng lớp

CHẤT LƯỢNG DỮ LIỆU

- Không có bản ghi trùng lặp
- Chỉ fraud_pattern có giá trị thiếu (98,3%) do đặc thù dữ liệu

INSIGHT

- Dataset mất cân bằng nghiêm trọng (chỉ 1,71% là fraud)
- Cần ưu tiên Recall, F1-score, ROC-AUC/PR-AUC thay vì chỉ Accuracy



PHÂN TÍCH BIẾN MỤC TIÊU — Tỷ lệ fraud: 1.71%




982.857 giao dịch hợp lệ vs. **17.143** giao dịch gian lận — tỷ lệ ~57:1.

Đây là đặc trưng kinh điển của bài toán fraud detection: lớp thiểu số cực kỳ hiếm, đòi hỏi kỹ thuật xử lý mất cân bằng và chỉ số đánh giá phù hợp (PR-AUC) thay vì Accuracy đơn thuần.

KHÁM PHÁ DỮ LIỆU

Các dạng gian lận phổ biến nhất





INSIGHT

- card_not_present (gian lận không cần thẻ vật lý) chiếm tỷ trọng lớn nhất – phù hợp xu hướng thanh toán trực tuyến
- account_takeover và card_present_stolen đứng kế tiếp, cho thấy rủi ro đến từ cả kênh online lẫn offline
- friendly_fraud và các dạng khác chiếm tỷ trọng nhỏ hơn nhưng vẫn cần giám sát riêng

KHÁM PHÁ DỮ LIỆU

Phân phối lệch phải




Các biến số chủ yếu có phân phối không chuẩn và xuất hiện đuôi dài. Điều này cho thấy dữ liệu chứa nhiều giá trị cực trị, vì vậy cần áp dụng các kỹ thuật tiền xử lý như chuẩn hóa và cân nhắc biến đổi Log đối với một số đặc trưng để hỗ trợ các mô hình nhạy cảm với phân phối dữ liệu.

KHÁM PHÁ DỮ LIỆU

Fraud tập trung tại vùng giá trị bất thường

BOXPLOT & FRAUD OUTLIERS




Các đặc trưng tài chính & hành vi có nhiều outlier. Đáng chú ý, các điểm fraud (màu đỏ) tập trung tại vùng outlier — giao dịch gian lận thường có giá trị bất thường so với phần còn lại. Vì vậy nhóm giữ lại outlier thay vì loại bỏ, và xử lý bằng chuẩn hóa + mô hình tree-based phù hợp.

KHÁM PHÁ DỮ LIỆU

Thiết bị & xác thực: tín hiệu fraud mạnh hơn thời gian

TỶ LỆ fraud THEO CÁC CỜ NHỊ PHÂN (BINARY FLAGS)



Các đặc trưng liên quan tới thiết bị (device_known), xác thực (has_2fa) và giao dịch quốc tế (is_foreign_txn) có khả năng phân biệt giao dịch gian lận tốt hơn đáng kể so với yếu tố thời gian như is_weekend (gần như không khác biệt: 1,71% vs 1,73%).

XỬ LÝ DỮ LIỆU

Split dữ liệu & xây dựng đặc trưng mới

1 · TIME-BASED SPLIT (OUT-OF-TIME)

Chia Train / Valid / Test theo thời gian (không random) — mô phỏng đúng kịch bản thực tế, tránh data leakage từ tương lai.

2 · LOẠI BỎ CỘT KHÔNG PHỤC VỤ MÔ HÌNH


`transaction_id`, `account_id`, `timestamp`, `fraud_pattern` — bị loại vì không có giá trị dự đoán hoặc gây leakage

3 · TẠO ĐẶC TRƯNG MỚI (11 FEATURES)

Log-transform (4)	<code>log_amount</code> , <code>log_ip_risk_score</code> , <code>log_amount_vs_avg_ratio</code> , <code>log_velocity_1h</code>
Binary flags (6)	<code>high_amount_flag</code> , <code>high_ip_risk_flag</code> , <code>high_velocity_1h_flag</code> , <code>high_utilization_flag</code> , <code>is_round_amount</code> , <code>is_night</code>
Ratio (1)	<code>utilization (amount / credit_limit)</code>

Output: 6 file Parquet (train/valid/test × log-branch, tree-branch)


MINH HỌA: TRƯỚC & SAU LOG TRANSFORM (AMOUNT)



NGUYÊN TẮC KHÔNG DATA LEAKAGE

- Tất cả fit() chỉ thực hiện trên Train
- Valid/Test chỉ dùng transform() với tham số đã fit sẵn
- Encoder, scaler, threshold đều lưu dưới dạng artifacts để đảm bảo pipeline production nhất quán

XỬ LÝ DỮ LIỆU (ENCODING & SCALING)



Việc xây dựng hai nhánh tiền xử lý giúp dữ liệu phù hợp với đặc điểm của từng nhóm mô hình, từ đó nâng cao hiệu quả huấn luyện và khả năng dự đoán

DANH SÁCH 4 MÔ HÌNH ĐƯỢC HUẤN LUYỆN

STT	Mô hình	Lý do chọn
1	Logistic Regression	Được sử dụng làm mô hình baseline để làm cơ sở so sánh với các mô hình khác.
2	XGBoost	Là mô hình boosting phổ biến, thường cho kết quả tốt trên dữ liệu dạng bảng và được dùng để đối chiếu hiệu năng với các mô hình khác.
3	LightGBM	Có tốc độ huấn luyện nhanh và đạt kết quả tốt trong nhiều bài toán phân loại trên dữ liệu tabular.
4	CatBoost	Được bổ sung để so sánh với các mô hình boosting khác và đánh giá khả năng xử lý dữ liệu phân loại.

QUY TRÌNH HUẤN LUYỆN

1. Đọc dữ liệu và cấu hình mô hình.
2. Xử lý mất cân bằng dữ liệu bằng SMOTE.
3. Huấn luyện lần lượt các mô hình.
4. Đánh giá mô hình trên tập validation thông qua các chỉ số Accuracy, Precision, Recall, F1-score, ROC-AUC và PR-AUC.
5. So sánh kết quả và chọn mô hình tốt nhất dựa trên PR-AUC.



Mô hình được đánh giá tốt nhất

Mô hình	Accuracy	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
LightGBM	99.25%	80.11%	75.25%	77.60%	99.40%	85.24%
XGBoost	99.21%	77.96%	76.20%	77.07%	99.33%	84.38%
CatBoost	99.21%	78.13%	75.42%	76.75%	99.34%	84.26%
Logistic Regression	95.60%	27.47%	94.02%	42.51%	99.01%	79.97%






Metric lựa chọn: PR-AUC (Precision-Recall Area Under Curve), phù hợp nhất cho dữ liệu mất cân bằng lớn.

Validation Confusion Matrices Across Baseline Models

Validation Precision-Recall Curves



MÔ HÌNH ĐƯỢC ĐÁNH GIÁ TỐT NHẤT




Nhận xét:

LightGBM được lựa chọn là mô hình baseline tốt nhất do đạt giá trị PR-AUC cao nhất trong quá trình đánh giá, cho thấy khả năng phát hiện giao dịch gian lận vượt trội so với các mô hình còn lại.

Bên cạnh hiệu năng dự đoán tốt, LightGBM còn có thời gian huấn luyện nhanh, sử dụng tài nguyên hiệu quả và hoạt động ổn định trên dữ liệu dạng bảng. Vì vậy, mô hình này được lựa chọn cho các bước tối ưu siêu tham số và các giai đoạn phát triển tiếp theo.

MÔ HÌNH ĐƯỢC ĐÁNH GIÁ TỐT NHẤT

LightGBM được lựa chọn làm mô hình baseline tốt nhất nhờ đạt PR-AUC cao nhất, đồng thời duy trì sự cân bằng tốt giữa Precision và Recall, giúp giảm đáng kể số lượng cảnh báo sai.



KẾT QUẢ SAU TUNING & THRESHOLD OPTIMIZATION

Siêu tham số tối ưu (LightGBM sau Optuna tuning)

Tham số	Giá trị tối ưu
n_estimators	1,235
max_depth	6
learning_rate	0.01066
num_leaves	48
min_child_samples	44
subsample	0.8867
colsample_bytree	0.8165
reg_alpha	0.0412
reg_lambda	7.076
Threshold tối ưu	0.30 (thay vì mặc định 0.50)

Kết quả trên tập Validation (sau tuning)

Chế độ	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
Default threshold (0.5)	99.19%	76.63%	76.77%	76.70%	99.35%	84.18%
Threshold tối ưu (0.3)	98.95%	65.61%	83.18%	73.36 %	99.35%	84.18%

Kết quả trên tập Test (đánh giá cuối cùng)

Chế độ	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
Default threshold (0.5)	99.20%	77.36%	76.64%	77.00 %	99.42%	85.73%
Threshold tối ưu (0.3)	98.97%	66.30%	82.82%	73.64 %	99.42%	85.73%


Nhận xét:

Threshold 0.3 giúp tăng khả năng phát hiện giao dịch gian lận (Recall đạt 82.82%) trong khi vẫn duy trì hiệu năng tổng thể tốt (PR-AUC = 85.73%), phù hợp với yêu cầu của bài toán fraud detection.

MÔ HÌNH HỌC ĐƯỢC GÌ?

CÁC ĐẶC TRƯNG QUAN TRỌNG NHẤT CỦA LIGHTGBM

STT	Feature	Ý nghĩa
1	device_known	Thiết bị đã từng sử dụng
2	log_velocity_1h	Tần suất giao dịch trong 1 giờ
3	log_ip_risk_score	Điểm rủi ro của IP
4	log_amount	Giá trị giao dịch
5	log_amount_vs_avg_ratio	Tỷ lệ giao dịch so với trung bình
6	utilization	Mức sử dụng hạn mức tín dụng
7	high_velocity_1h_flag	Cờ giao dịch tần suất cao
8	high_ip_risk_flag	Cờ IP rủi ro cao
9	is_night	Giao dịch ban đêm
10	is_foreign_txn	Giao dịch quốc tế




Một số insight đáng chú ý:

1. Giao dịch từ thiết bị lạ có xác suất gian lận cao hơn đáng kể.
2. Tần suất giao dịch tăng đột biến thường là dấu hiệu của fraud.
3. IP rủi ro cao và giao dịch giá trị lớn làm tăng nguy cơ gian lận.

DEPLOYMENT


Người dùng nhập thông tin giao dịch thông qua giao diện Streamlit. Dữ liệu sau đó được gửi đến FastAPI Server thông qua API /predict dưới dạng HTTP POST.

Tại đây, hệ thống thực hiện các kỹ thuật đặc trưng, tiền xử lý dữ liệu và đưa vào mô hình LightGBM để dự đoán xác suất gian lận. Kết quả cuối cùng bao gồm điểm gian lận, mức độ rủi ro và các luật cảnh báo được trả về cho người dùng dưới dạng JSON.



DEPLOYMENT

Hệ thống được triển khai trên GKE, trong đó FastAPI và mô hình LightGBM chạy trong container fraud-api. Hệ thống sử dụng GitHub Actions cho CI/CD, Grafana và Evidently AI để giám sát, AWS S3/GCS để lưu trữ dữ liệu, và MLflow để theo dõi các thí nghiệm.



DEPLOYMENT

Giao diện Streamlit cho phép người dùng nhập thông tin giao dịch và xem trực quan kết quả dự đoán, bao gồm điểm gian lận, mức độ rủi ro và các cảnh báo, thông qua kết nối trực tiếp với API FastAPI trên GKE.

The screenshot displays the 'FraudGuard' application interface. On the left is a dark sidebar with navigation links: 'Dashboard', 'Transactions', 'Alerts', 'Settings', 'Docs', and 'Security'. The main content area is titled 'TRANSACTION ANALYSIS' and 'FRAUD_DETECTION_ENGINE'. It features a 'Transaction Parameters' section with input fields for 'TRANSACTION ID *' (containing 'TXN-000001') and 'USER ID *' (containing 'USR-000001'). Below these are dropdown menus for 'HOUR OF DAY *' (set to '8-23'), 'DAY OF WEEK *' (set to '4 - Friday'), and 'IS WEEKEND *' (set to 'No (0)'). A 'Lookup TXN...' button is located in the top right. To the right of the form is a large box labeled 'AWAITING ANALYSIS' with the text 'Fill form > Run Analysis Engine'.

KẾT LUẬN

MÔ HÌNH TỐT NHẤT

Mục	Chi tiết
Mô hình	LightGBM
PR-AUC (Test)	85.73%
ROC-AUC (Test)	99.42%
Recall (Test, threshold=0.3)	82.82% — phát hiện được hơn 82% giao dịch gian lận
Precision (Test, threshold=0.3)	66.30% — đảm bảo precision floor $\geq 65\%$
Threshold tối ưu	0.30 (tối ưu hóa Recall với ràng buộc Precision $\geq 65\%$)

HẠN CHẾ

Dữ liệu synthetic: Dataset được tạo mô phỏng, có thể không phản ánh hết sự phức tạp của dữ liệu giao dịch thực tế (real-world).

Threshold cố định: Threshold = 0.3 được tối ưu trên validation set; trong production có thể cần điều chỉnh linh hoạt theo thời gian (concept drift).

SMOTE trên toàn bộ features: SMOTE tạo mẫu tổng hợp trong không gian nhiều chiều, có thể tạo ra noise nếu features không đồng nhất.

ĐỀ XUẤT HƯỚNG PHÁT TRIỂN

Deep Learning: Thử nghiệm mô hình Neural Network (e.g., TabNet, AutoEncoder cho anomaly detection) để so sánh với tree-based models.

Feature Store: Xây dựng Feature Store (e.g., Feast) để quản lý features tập trung, phục vụ cả training và inference.

Real-time streaming: Tích hợp Apache Kafka / Pub-Sub để xử lý giao dịch real-time thay vì batch.

TÀI LIỆU THAM KHẢO

Dataset

- Synthetic Financial Transaction Dataset (tạo mô phỏng, lưu trữ trên Google Drive)
- Dữ liệu quản lý phiên bản bằng DVC với backend AWS S3

Công cụ & Framework sử dụng

Category	Tools
Ngôn ngữ	Python 3.11
Quản lý môi trường	uv
Xử lý dữ liệu	Pandas, NumPy
Machine Learning	scikit-learn, XGBoost, LightGBM, CatBoost
Hyperparameter Tuning	Optuna
Experiment Tracking	MLflow
Pipeline Management	DVC (Data Version Control)
API Serving	FastAPI, Uvicorn
Web UI	Streamlit
Containerization	Docker
Orchestration	Kubernetes (Google Kubernetes Engine)
Data/Model Drift	Evidently AI
Monitoring Metrics	Prometheus

GitHub Repository

- <https://github.com/huyvietbui1806/mlops-project>

Tài liệu liên quan

- scikit-learn Documentation: <https://scikit-learn.org/>
- LightGBM Documentation: <https://lightgbm.readthedocs.io/>
- XGBoost Documentation: <https://xgboost.readthedocs.io/>
- CatBoost Documentation: <https://catboost.ai/docs/>
- FastAPI Documentation: <https://fastapi.tiangolo.com/>
- MLflow Documentation: <https://mlflow.org/docs/latest/>
- DVC Documentation: <https://dvc.org/doc>
- Evidently AI: <https://www.evidentlyai.com/>
- SMOTE (Chawla et al., 2002): *"SMOTE: Synthetic Minority Over-sampling Technique"*
- Optuna: <https://optuna.org/>